

Đánh giá khả năng sinh Gherkin từ Connextra User Stories bằng GPT-4o

Nhóm 4

Tống Vỹ Thuận (SE194643) · Võ Hiếu Chương (SE204862) · Nguyễn Hiếu An (SE205060)
Trần Tuấn Khang (SE204881) · Nguyễn Minh Hoàng (SE204811)

Proposal Presentation — Tuần 6

Vấn đề nghiên cứu & GAP

BỐI CẢNH

- BDD (Phát triển hướng hành vi) kết nối yêu cầu → kiểm thử qua ngôn ngữ Gherkin
- Viết Gherkin thủ công tốn thời gian, dễ sai cú pháp
- LLM (AI ngôn ngữ lớn) có thể tự động hóa bước này
- Nhưng chưa ai đánh giá GPT-4o cho task cụ thể này

GAP

- GAP-T: Chưa ai dùng GPT-4o bản full
- GAP-M1: Chưa ai đo Cosine Similarity (all-MiniLM-L6-v2)
- GAP-M2: Chưa ai dùng behave parser kiểm tra cú pháp
- GAP-D: Chưa ai test trên dataset Connextra công khai $\geq$ 50 US

GAP STATEMENT

Không có nghiên cứu nào đánh giá GPT-4o (official API, zero-shot, temperature=0) cho việc sinh Gherkin acceptance test scenarios từ user story format Connextra, đo bằng cosine semantic similarity (all-MiniLM-L6-v2) $\geq$ ngưỡng so với expert-written Gherkin VÀ executable syntax rate bằng Gherkin parser (behave --dry-run) $\geq$ ngưỡng.

Căn cứ: 30/30 papers trong evidence table xác nhận.

Nghiên cứu liên quan (Related Work)

Paper	LLM	Dataset	Metric chính	Kết quả tốt nhất	Hạn chế
Rathnayake 2026	GPT-4	500 US (riêng)	BERTScore	91.16%	Không dùng GPT-4o
Fernandes 2025	GPT-4o Mini	10 mẫu	METEOR	0.84 (Gemini)	N quá nhỏ
Karpurapu 2024	GPT-3.5/4	~50 US (Mendeley)	Gherkin-lint	~0 lỗi	Lint ≠ Parser thật
Varpe 2025	Qwen	PURE (SRS)	BERTScore F1	80.58%	SRS ≠ Connextra
Ferreira 2025	GPT-4 Turbo	13 US (ô tô)	Syntactic check	100%	N=13, không 4o

→ Nhận xét chung:

- Đa số dùng phiên bản LLM cũ (GPT-4, GPT-3.5), chưa ai dùng GPT-4o bản full
- Metric: linter tĩnh hoặc N-gram (METEOR/BLEU) — thiếu kết hợp semantic + parser thật
- Dataset: nhỏ hoặc riêng doanh nghiệp — thiếu dataset Connextra công khai

★ Research Questions — Câu hỏi nghiên cứu

RQ1 — Về ý nghĩa (Semantic)

GPT-4o zero-shot sinh Gherkin có đạt cosine similarity ≥ 0.85 so với chuyên gia viết không?

H0: $\mu_{\text{sim}} \leq 0.85$

H1: $\mu_{\text{sim}} > 0.85$

Metric: Cosine Similarity (all-MiniLM-L6-v2)

Threshold: 0.85 — Case 3

→ Tham chiếu METEOR 0.84 (Fernandes 2025)

→ Xác nhận qua pilot Tuần 7

Test: Wilcoxon signed-rank (one-tailed)

$\alpha = 0.05$ | Effect size: Cliff's delta

RQ2 — Về cú pháp (Executable)

GPT-4o zero-shot sinh Gherkin có đạt tỷ lệ parse thành công $\geq 80\%$ (behave --dry-run) không?

H0: $p_{\text{exec}} \leq 0.80$

H1: $p_{\text{exec}} > 0.80$

Metric: Executable Syntax Rate (behave parser)

Threshold: 80% — Case 2

→ Floor value từ Storer 2019 (80%)

→ Bảo thủ hơn Fonseca 2025 (93.3%)

Test: Binomial exact test (one-tailed)

$\alpha = 0.05$

Pipeline thí nghiệm (Experiment Protocol)



Input: User Stories (.csv) → Output: metric_results.json + p-values + biểu đồ

Cấu hình cố định: Model = gpt-4o-2024-05-13 | Temperature = 0 | Top_p = 1.0 | Max_tokens = 1500 | Strategy = Zero-shot | Embedding = all-MiniLM-L6-v2

Dataset & Baseline

DATASET

Tên: Requirements data sets (user stories)

Tác giả: Fabiano Dalpiaz (2018)

Nguồn: Mendeley Data

DOI: 10.17632/7zbk8zsd8y

Quy mô: 22 file, ~1000+ user stories

N thực dùng: ≥ 50 (chọn từ ≥ 3 domain)

Format: Connextra chuẩn (As a... I want... So that...)

✓ Accessible: Đã verify, link public hoạt động

✓ Đa domain: gov, finance, healthcare, PM

BASELINE (Đáp án chuẩn)

Expert-written Gherkin (.feature files)

Nguồn ưu tiên:

1. File .feature có sẵn từ repo open-source (Spring, Cucumber-JS, etc.)
2. Viết bởi role DG theo rubric nghiêm ngặt

Đánh giá tự động:

- Cosine Similarity tính bằng script Python
- Không có yếu tố chủ quan con người

Kế hoạch thống kê (Statistical Plan)

RQ	Metric	Ngưỡng	Test	Chiều	α	Effect Size
RQ1	Cosine Similarity	≥ 0.85	Wilcoxon signed-rank	One-tailed (greater)	0.05	Cliff's delta
RQ2	Executable Rate	$\geq 80\%$	Binomial exact	One-tailed (greater)	0.05	—

Diễn giải tổ hợp kết quả:

Kịch bản	RQ1 (Ý nghĩa)	RQ2 (Cú pháp)	Ý nghĩa thực tế
🏆 Tốt nhất	✔ Đạt ≥ 0.85	✔ Đạt $\geq 80\%$	Áp dụng ngay vào CI/CD pipeline
⚠ Đúng ý, sai form	✔ Đạt	✘ Không đạt	Cần post-processor sửa syntax
⚠ Đúng form, sai ý	✘ Không đạt	✔ Đạt	AI bị hallucination → cần RAG/few-shot
😞 Thất bại	✘ Không đạt	✘ Không đạt	Cần fine-tuning hoặc đổi model

Mối đe dọa tính hiệu lực (Threats to Validity)

INTERNAL (Bên trong)

⚠️ **Rủi ro:**

OpenAI có thể âm thầm cập nhật model

✓ **Xử lý:**

Pin version gpt-4o-2024-05-13
Lưu fingerprint mỗi API call

EXTERNAL (Bên ngoài)

⚠️ **Rủi ro:**

Test 1 domain → thiếu tính tổng quát

✓ **Xử lý:**

Dataset Dalpiaz: 22 dự án từ nhiều lĩnh vực khác nhau

CONSTRUCT (Cấu trúc)

⚠️ **Rủi ro:**

Cosine cao $\neq$ đúng logic nghiệp vụ

✓ **Xử lý:**

Dùng thêm RQ2 (behave parser)
làm metric bảo vệ bổ sung

CONCLUSION (Kết luận)

⚠️ **Rủi ro:**

N quá nhỏ → thiếu statistical power

✓ **Xử lý:**

$N \geq 50$ (power ≥ 0.80)
Dùng exact test, không xấp xỉ

Timeline & Phân công

Tuần	Hoạt động chính	Owner	Output
5	Nộp proposal + Tải dataset + Setup API + Code metric	All	proposal.md, test_api.py
6	★ GV phê duyệt proposal	GV	proposal.md Approved
7	Pilot 10 mẫu + Review kết quả + Amendment (nếu cần)	LR+MS	pilot_results.csv
8	Full experiment 50+ mẫu + Statistical tests + Figures	LR+MS+RW	full_analysis.ipynb
9-10	Viết báo cáo + Thuyết trình	All	Report + Slide

Phân công vai trò:

Role	Thành viên	Trách nhiệm chính
PL (Trưởng nhóm)	Nguyễn Minh Hoàng	Điều phối, review, submit GV
DG (Thu thập dữ liệu)	Trần Tuấn Khang	Dataset + Ground truth + §3
LR (Chạy thí nghiệm)	Nguyễn Hiếu An	API + Script + Batch processing
MS (Đo điểm)	Võ Hiếu Chương	Metric + Statistical tests
RW (Viết báo cáo)	Tống Vỹ Thuận	Intro/Conclusion/Threats + Figures

Đóng góp dự kiến

1. Benchmark đầu tiên đánh giá GPT-4o cho task sinh Gherkin từ Connextra user stories trên dataset công khai
2. Framework đánh giá kép (semantic + executable) sử dụng cosine similarity (all-MiniLM) + parser thật (behave)

Q & A